

Programa de formación
MACHINE LEARNING AND DATA SCIENCE MLDS

Facultad de
INGENIERÍA

UNIVERSIDAD NACIONAL DE COLOMBIA

Módulo 4

Procesamiento y Entendimiento del Lenguaje Natural

Contenido inicial

Felipe Restrepo Calle, PhD.

Facultad de INGENIERÍA

UNIVERSIDAD NACIONAL DE COLOMBIA



¡Le damos la bienvenida al cuarto módulo del programa de formación MLDS: NLP!

En este módulo aprenderá los conceptos fundamentales del procesamiento y entendimiento del lenguaje natural (NLP), sus distintas aplicaciones y las particularidades de los proyectos de análisis automático de textos. Al mismo tiempo obtendrá experiencia práctica en la selección de herramientas adecuadas de acuerdo a la naturaleza de distintos problemas.

Esperamos que disfrute la experiencia y que el conocimiento adquirido sea provechoso para progresar en su actividad profesional.

Meta

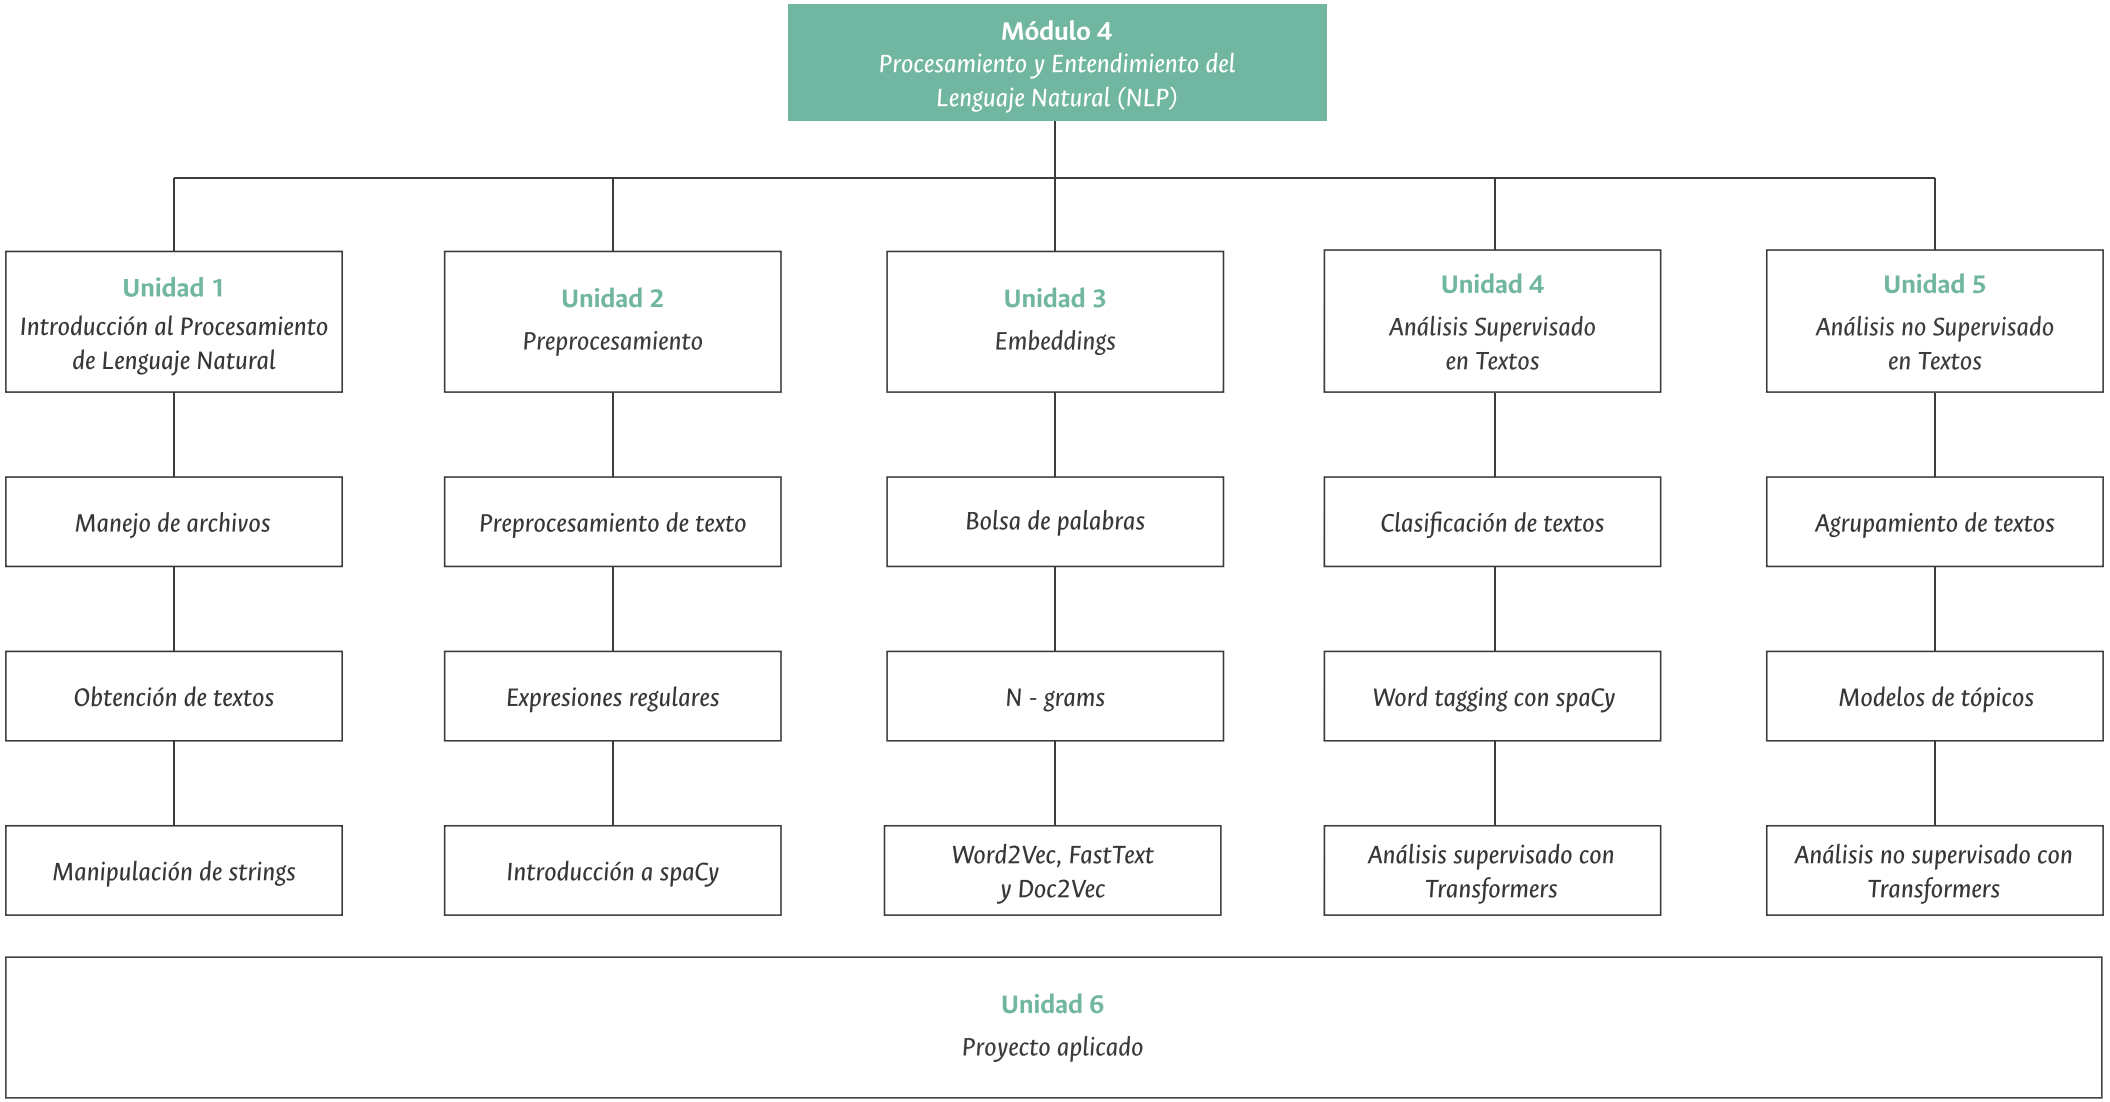


La meta de este módulo es aprender acerca de los temas y conceptos fundamentales en el procesamiento de lenguaje natural (NLP, por sus siglas en inglés) por medios computacionales y con énfasis en textos escritos.

Se estudiarán una amplia gama de técnicas para la lingüística computacional, el análisis estadístico del lenguaje y la minería de textos, aplicadas a problemas como: análisis sintáctico, extracción de información, clasificación y agrupamiento de texto, análisis de sentimientos, modelos de tópicos, entre otros.

Todo ello, mediante el uso del lenguaje de programación Python y sus librerías especializadas para NLP.

Mapa de contenidos



Objetivos de aprendizaje



Objetivos de aprendizaje

Módulo 4: Procesamiento y Entendimiento del Lenguaje Natural

Al finalizar el módulo usted deberá ser capaz de:

1. Entender los conceptos fundamentales del procesamiento y entendimiento del lenguaje natural (NLP), sus distintas aplicaciones y las particularidades de los proyectos de análisis automático de textos.

2. Conocer y aplicar los fundamentos de programación de computadores y computación científica para el procesamiento automático de textos mediante el lenguaje de programación *Python* y sus librerías especializadas para NLP.

3. Cargar y pre-procesar un *corpus* textual usando el lenguaje de programación *Python* y su librería para el procesamiento de lenguaje natural *spaCy*.

4. Entender las técnicas clásicas de extracción de características o representaciones semánticas en NLP y aplicarlas por medio de librerías especializadas como *sklearn* y *gensim* para procesamiento de lenguaje natural con *Python*.

5. Aplicar técnicas de aprendizaje de máquina supervisado y no supervisado en las tareas típicas en NLP para un análisis detallado sobre información textual.

Objetivos de aprendizaje

Unidad 1 – Introducción a NLP

Al finalizar la unidad usted deberá ser capaz de:



Describir de manera precisa los conceptos generales del procesamiento de lenguaje natural (NLP), los retos propios del análisis automático de lenguaje natural y conocer los distintos tipos de aplicaciones que actualmente involucran NLP.



Utilizar distintas librerías y utilidades del lenguaje de programación *Python* para la obtención de información textual.



Manipular textos como cadenas de caracteres en *Python*, incluyendo operaciones básicas con *strings*, formatos, búsquedas exactas y mediante patrones.

Objetivos de aprendizaje

Unidad 2 – Preprocesamiento

Al finalizar la unidad usted deberá ser capaz de:



Describir la relación entre un proyecto de NLP y un proyecto de Ciencia de Datos/*Machine Learning*.



Entender las expresiones regulares como una técnica para búsqueda y limpieza en procesamiento de lenguaje natural.



Seleccionar la estrategia de preprocesamiento más adecuada para diversos datos textuales.



Utilizar la librería *spaCy* para procesamiento de lenguaje natural y entender sus módulos y componentes básicos.

Objetivos de aprendizaje

Unidad 3 – *Embeddings*

Al finalizar la unidad usted deberá ser capaz de:



Entender el proceso de extracción de características y representación semántica en procesamiento de lenguaje natural.



Utilizar los *embeddings* clásicos como las bolsas de palabras, *Word2Vec, Doc2Vec y FastText* para construir representaciones vectoriales de la semántica del texto.



Utilizar librerías del lenguaje de programación *Python* como *sklearn* y *gensim* para procesamiento de lenguaje natural.

Objetivos de aprendizaje

Unidad 4 – Análisis Supervisado en Textos

Al finalizar la unidad usted deberá ser capaz de:



Entender cómo se aplican los enfoques de aprendizaje supervisado de máquina en procesamiento de lenguaje natural.



Seleccionar el tipo de tarea supervisada en dependencia de la necesidad de clasificación de texto.



Utilizar modelos pre-entrenados para clasificar palabras o documentos y entrenar modelos personalizados para una tarea específica de procesamiento de texto.

Objetivos de aprendizaje

Unidad 5 – Análisis no Supervisado en Textos

Al finalizar la unidad usted deberá ser capaz de:



Entender cómo se aplican los enfoques de aprendizaje no supervisado de máquina en procesamiento de lenguaje natural.



Seleccionar el tipo de tarea no supervisada en dependencia de la necesidad de análisis de texto.



Utilizar distintos modelos de agrupamiento de texto y tópicos para el análisis no supervisado de textos.

Objetivos de aprendizaje

Unidad 6 - Proyecto aplicado

Al finalizar la unidad usted deberá ser capaz de:



Ejecutar un proyecto de procesamiento y entendimiento automático de lenguaje natural de forma efectiva usando las técnicas y herramientas presentadas en el curso con el objetivo de hallar información relevante en los textos analizados.

Palabras clave del módulo



Conceptos previos



- Programación básica en Python
- Uso de librerías científicas como:

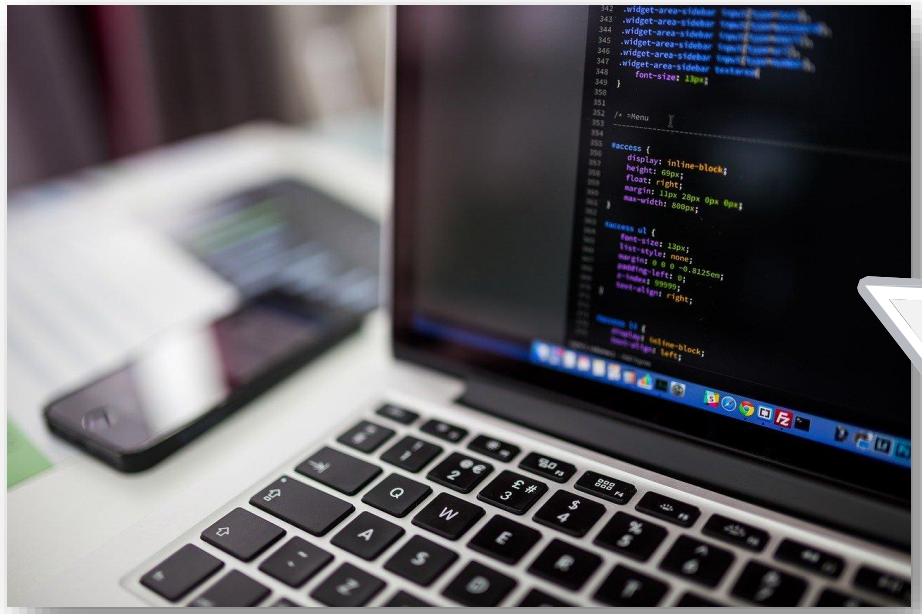
NumPy matplotlib scikit learn pandas

Habilidades y competencias a desarrollar



Habilidades y competencias a desarrollar

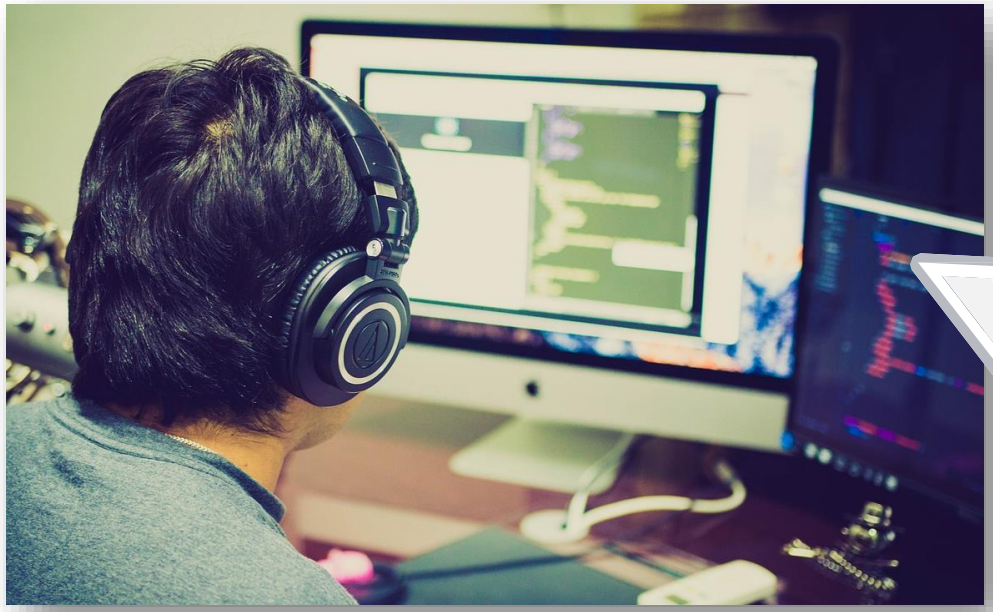
Saber



- Qué es el Procesamiento de Lenguaje Natural.
- Librerías de Python para el NLP.
- Adquisición, manipulación, procesamiento y análisis de textos
- Aplicación de análisis supervisado en textos.

Habilidades y competencias a desarrollar

Saber hacer



- Uso de la librería *spaCy* para NLP en general.
- Uso de la librería *Transformers* para modelos de NLP basados en redes neuronales.
- Uso de la librería *Gensim* para modelos de *embeddings*.
- Implementación de modelos de *Machine Learning* y *scikit-learn* para NLP.

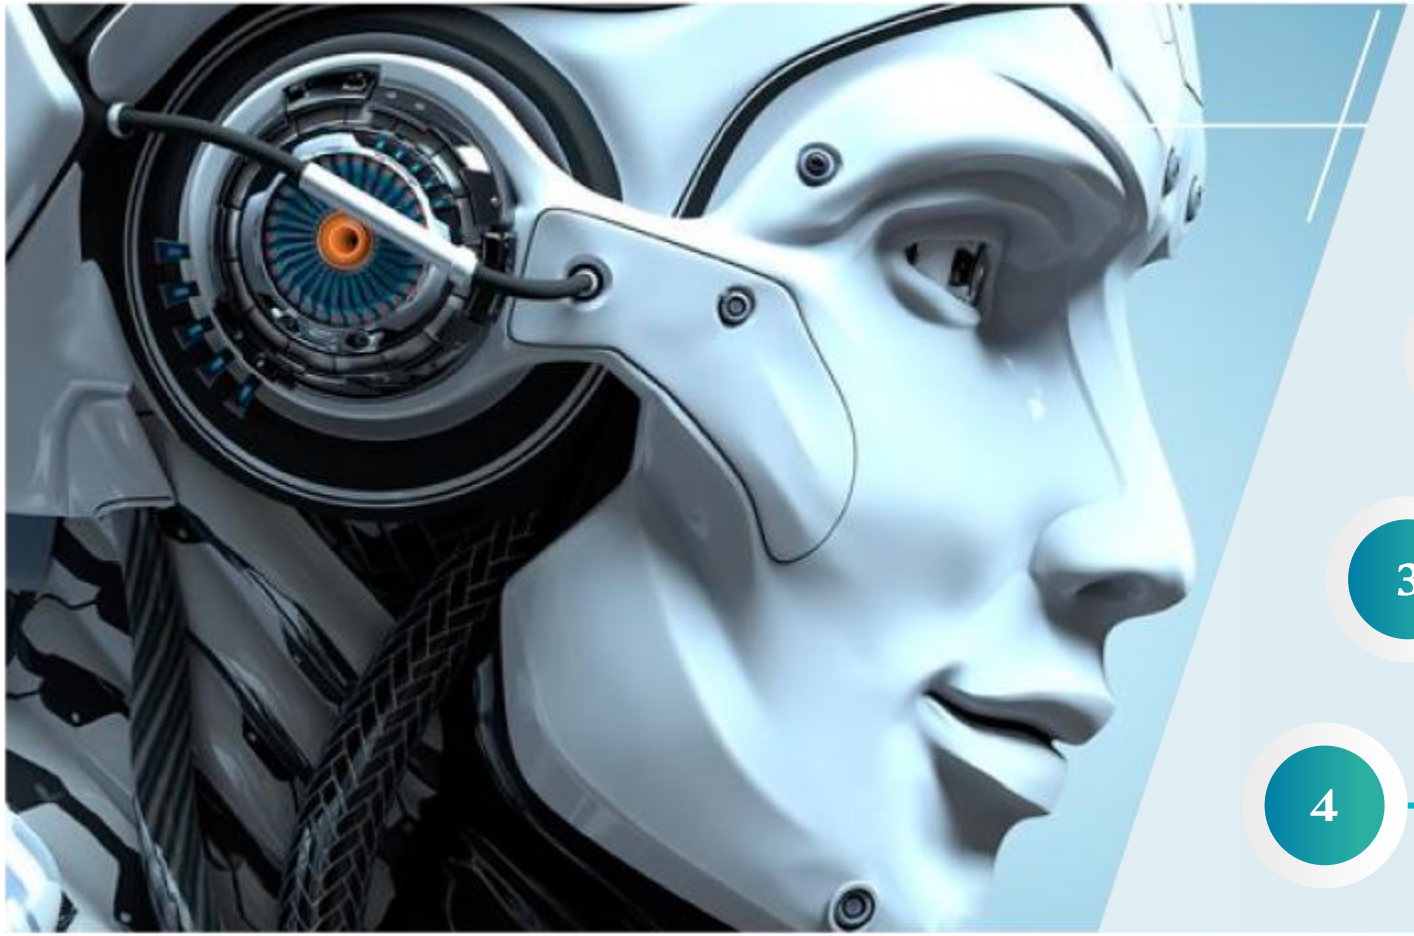
Habilidades y competencias a desarrollar

Saber ser



- Capacidad de entendimiento de lenguajes a través de la lingüística computacional.
- Solucionar problemas relacionados a información en lenguajes humanos.
- Análisis de lenguajes con técnicas computacionales.
- Capacidad de usar modelos de Deep learning para NLP en escenarios más prácticos.

Evaluación formativa del módulo



1. Talleres: 50%
2. Proyecto: 30%
3. Participación: 15%
4. Autoevaluación: 5%



¡Felicitaciones!

Ha concluido la introducción del cuarto módulo del programa de formación MLDS: *NLP*.

Le invitamos a continuar en la plataforma con la primera unidad del módulo.

Créditos

Facultad de
INGENIERÍA

Profesor
Felipe Restrepo-Calle, PhD

Asistente docente
Juan Sebastián Lara Ramírez

Coordinador de virtualización
Edder Hernández Forero

Diagramadora PPT
Rosa Alejandra Superlano Esquibel



Fecha
2023-I