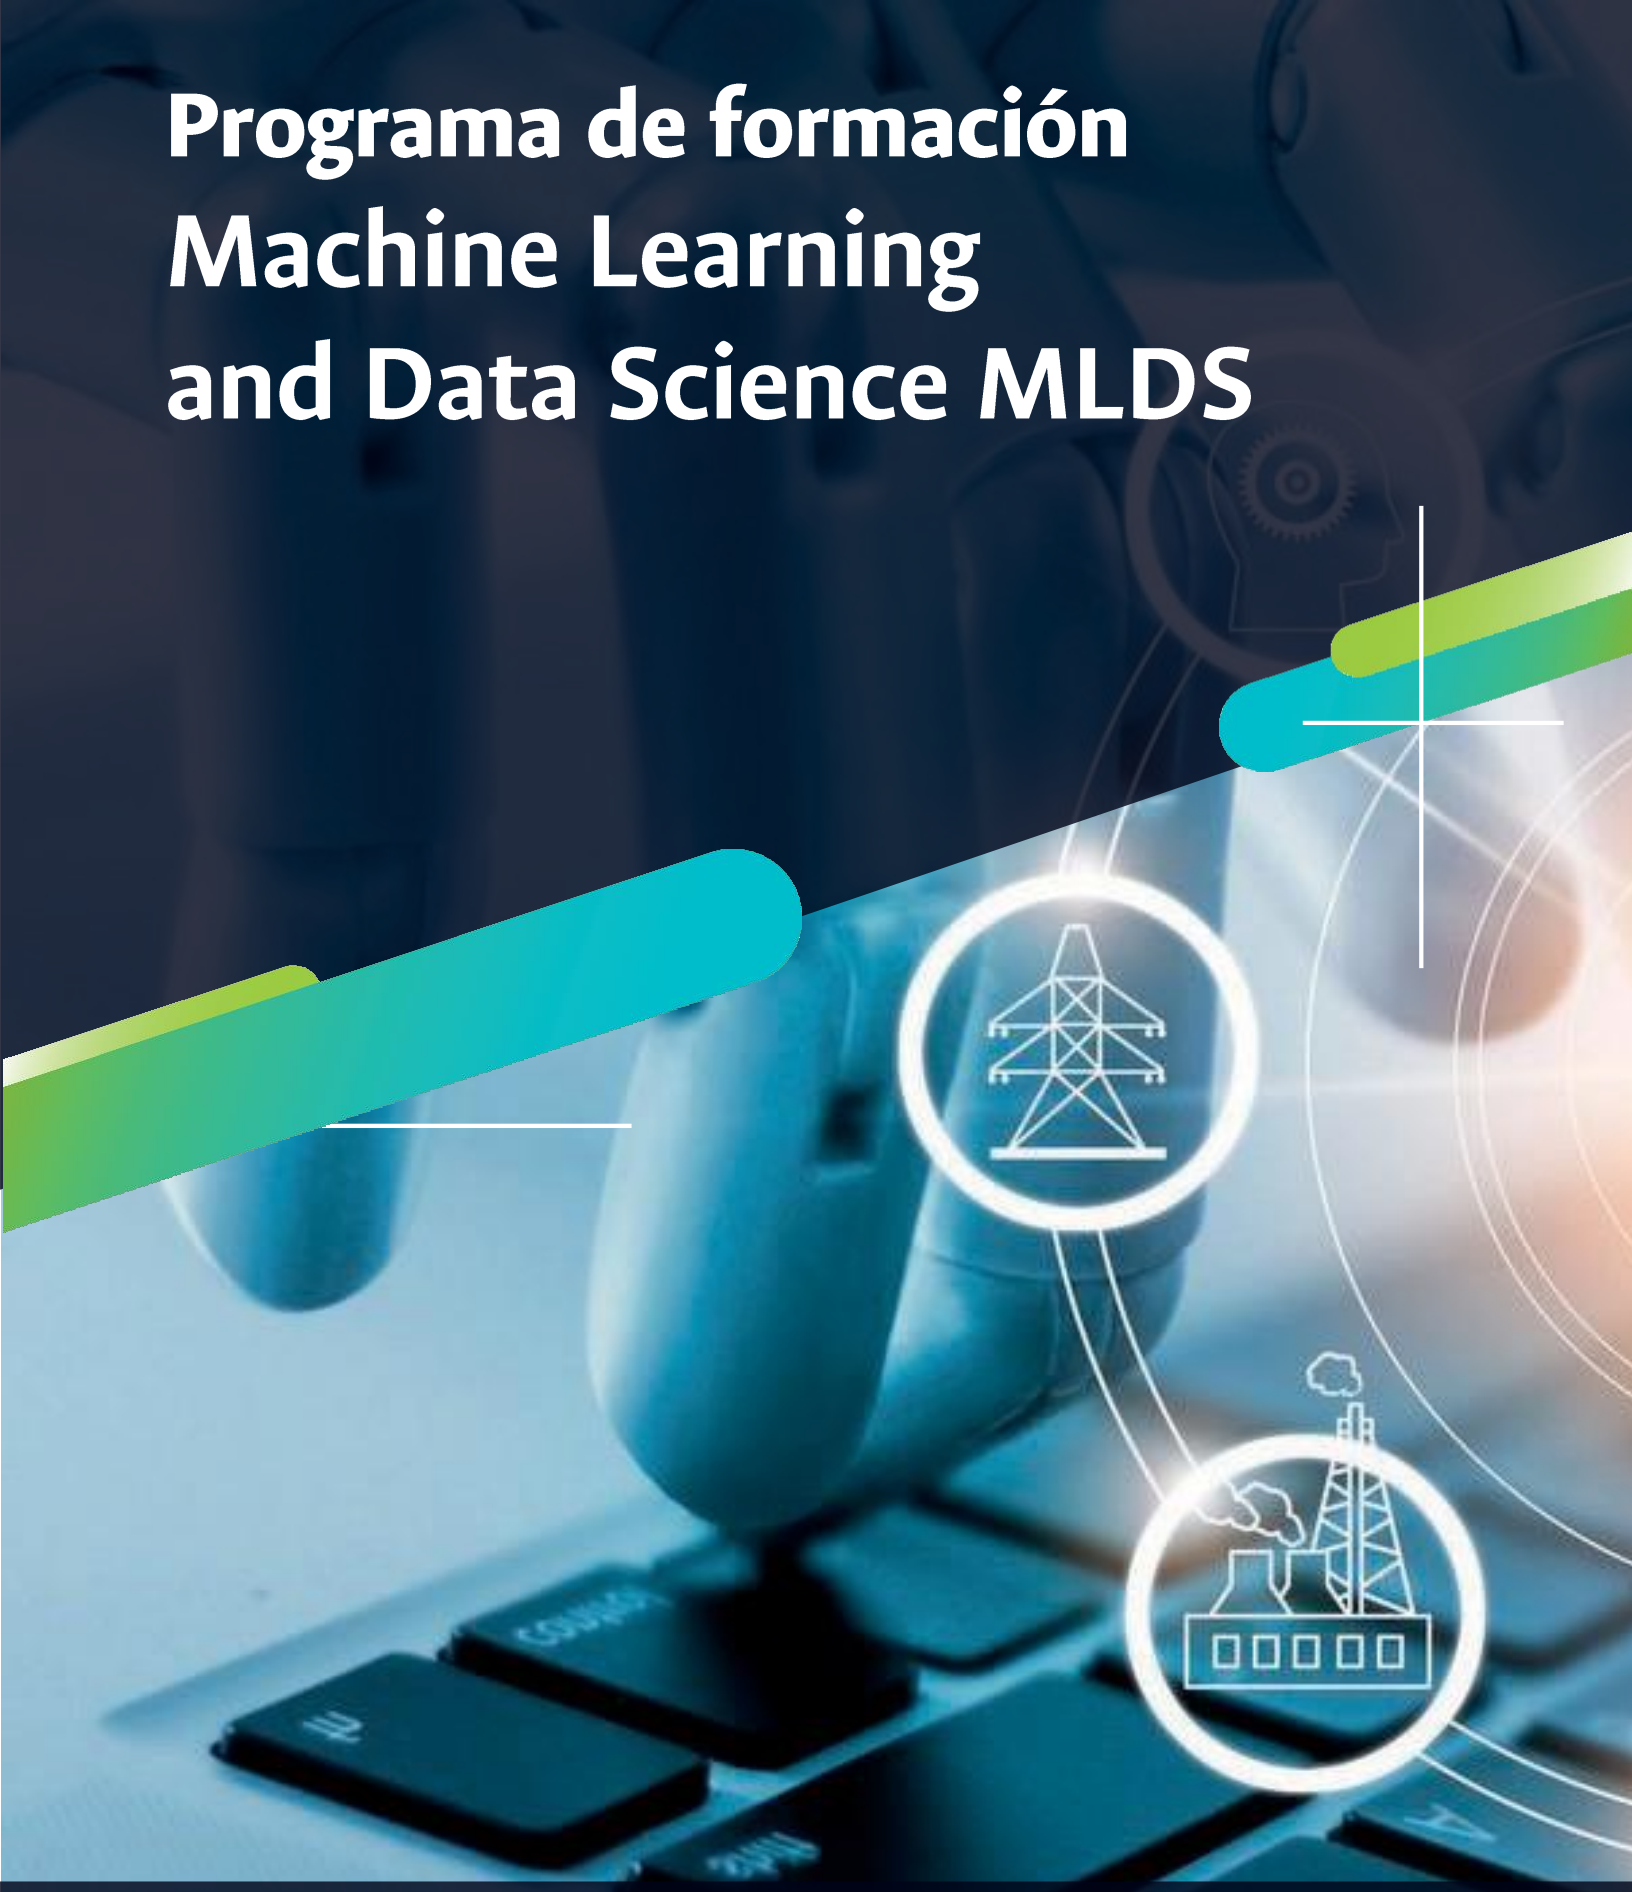
Programa de formación Machine Learning and Data Science MLDS



Facultad de
INGENIERÍA
Sede Bogotá

UNIVERSIDAD
NACIONAL
DE COLOMBIA

Módulo 4

Procesamiento y entendimiento del lenguaje natural

Proyecto Aplicado
Conjunto de Datos



Facultad de
INGENIERÍA
Sede Bogotá

UNIVERSIDAD
NACIONAL
DE COLOMBIA

Conjunto de datos

El planteamiento y desarrollo del proyecto no es restrictivo en la elección del conjunto de datos. Si lo desea puede realizar un proyecto personal/laboral que aplique los conceptos y herramientas discutidas en el transcurso del curso. Si tiene dificultad para encontrar un tema para su proyecto, dejamos a su disposición algunos temas propuestos de los que se puede guiar para llevar a cabo la actividad.

A continuación, se presentan algunas plataformas con distintos *dataset* disponibles con datos para procesamiento de lenguaje natural:

Kaggle:

Kaggle es una plataforma en línea que ofrece competiciones de aprendizaje automático y una comunidad de data scientists y analistas de datos. En Kaggle, los usuarios compiten para resolver problemas y mejorar sus habilidades en ciencia de datos a través de la participación en desafíos reales con datasets reales. También ofrece una amplia gama de herramientas y recursos para el análisis de datos y el aprendizaje automático.

Kaggle es una plataforma popular para NLP (Procesamiento del Lenguaje Natural) debido a las siguientes razones:

- **Datasets**: Kaggle cuenta con una amplia variedad de datasets de NLP disponibles para su uso, incluyendo texto, audio y lenguaje hablado.
- **Comunidad**: Kaggle cuenta con una comunidad activa de expertos en NLP que pueden proporcionar apoyo y asesoramiento sobre técnicas y herramientas.
- **Competencias**: Kaggle ofrece competiciones regulares en NLP que permiten a los usuarios poner a prueba sus habilidades y mejorar sus modelos.
- **Herramientas**: Kaggle proporciona herramientas de análisis de datos y aprendizaje automático integradas para resolver problemas de NLP, como Jupyter Notebooks y recursos de procesamiento de GPU.

Google Dataset Search:

Google Dataset Search es una herramienta de búsqueda de datos de Google que permite a los investigadores, científicos de datos y otros interesados en encontrar y explorar datasets relevantes. Es un motor de búsqueda especializado que se centra en la localización de datasets en línea, incluyendo conjuntos de datos públicos y privados.

Con Google Dataset Search, los usuarios pueden realizar búsquedas basadas en palabras clave o frases relevantes y obtener resultados con información sobre la descripción, la fuente y el formato de los datasets.

Conjunto de datos

Además, Google Dataset Search también incluye características como la capacidad de filtrar los resultados por formato de archivo, publicación y fecha.

Google Dataset Search puede ser útil para NLP (Procesamiento del Lenguaje Natural) por las siguientes razones:

- **Accesibilidad**: Google Dataset Search permite a los investigadores y profesionales de NLP encontrar fácilmente datasets relevantes para sus proyectos de NLP.
- **Variedad de datos**: Hay una amplia variedad de datasets de NLP disponibles en Google Dataset Search, incluyendo texto, audio y lenguaje hablado.
- **Información relevante**: Los resultados de búsqueda incluyen información relevante sobre el dataset, como la descripción, la fuente y el formato, lo que puede ayudar a los usuarios a tomar decisiones informadas sobre qué datasets utilizar.
- **Búsqueda basada en palabras clave**: Google Dataset Search permite a los usuarios realizar búsquedas basadas en palabras clave relevantes para sus proyectos de NLP, lo que ahorra tiempo y esfuerzo en la búsqueda manual de datasets.

DataHub:

DataHub es un repositorio en línea de datasets abiertos que permite a los usuarios acceder, explorar y descargar conjuntos de datos públicos. La plataforma alberga una amplia variedad de datasets de diferentes categorías, incluyendo ciencias sociales, ciencias naturales y tecnología.

DataHub.io es una herramienta útil para los investigadores, científicos de datos y profesionales que buscan acceder a datasets abiertos para sus proyectos. La plataforma ofrece una interfaz fácil de usar para buscar y descargar datasets, así como la capacidad de visualizar y analizar los datos en línea.

DataHub.io puede ser útil para NLP (Procesamiento del Lenguaje Natural) por las siguientes razones:

- **Fuentes confiables**: DataHub.io aloja datasets abiertos de alta calidad y confiables que pueden ser utilizados para proyectos de NLP.
- **Amplia variedad de datos**: DataHub.io alberga una amplia variedad de datasets relacionados con el lenguaje, incluyendo texto, audio y lenguaje hablado.
- **Interfaz fácil de usar**: La plataforma ofrece una interfaz intuitiva para buscar y descargar datasets, lo que ahorra tiempo y esfuerzo.
- **Análisis en línea**: DataHub.io permite a los usuarios visualizar y analizar los datos en línea, lo que puede ser útil para el preprocesamiento de los datos antes del uso en proyectos de NLP.

Programa de formación
Machine Learning and Data Science MLDS

Facultad de
INGENIERÍA
Sede Bogotá

UNIVERSIDAD
NACIONAL
DE COLOMBIA